POLITECHNIKA BIAŁOSTOCKA

WYDZIAŁ INFORMATYKI

PRACA BADAWCZA

TEMAT: Rozpoznawanie gatunków muzycznych z wykorzystaniem metod uczenia maszynowego

WYKONAWCY: Paweł Oświeciński
Michał Puławski
Aleksander Żyliński

BIAŁYSTOK 2026 ROK

Spis treści

1 Wstęp **1**

2 Opis zmian **2**

3 Tło projektu **3**

3.1 Konsultacja z ludzkim ekspertem. 3

3.2 Konsultacja ze sztuczną inteligencją. 4

3.3 Przegląd podobnych rozwiązań. 6

3.4 Stan wiedzy. 7

3.5 Uwarunkowania licencyjne. 8

3.6 Uwarunkowania komercyjne. 10

3.7 Dostępne bazy danych. 11

4 Analiza wymagań **13**

4.1 Cel projektu. 13

4.2 Charakterystyka problemu. 13

4.3 Metody badawcze. 13

4.4 Oczekiwane rezultaty. 13

4.5 Zakres danych i kryteria sukcesu. 14

4.6 Wymagania funkcjonalne. 15

4.7 Wymagania niefunkcjonalne. 15

4.8 Założenia i kwestie do ustalenia. 15

5 Zakres projektu i harmonogram **16**

6 Szczegółowa specyfikacja projektu i opis wymagań 17

7 Opis wyników prac 18

8 Oświadczenie wykorzystania narzędzi GenAI 19

1. Wstęp

Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do eiusmod tempor incididunt ut labore et dolore magnam aliquam quaerat voluptatem. Ut enim aeque doleamus animo, cum corpore dolemus, fieri tamen permagna accessio potest, si aliquod aeternum et infinitum impendere malum nobis opinemur. Quod idem licet transferre in voluptatem, ut postea variari voluptas distinguique possit, augeri amplificarique non possit. At etiam Athenis, ut e patre audiebam facete et urbane Stoicos irridente, statua est in quo a nobis philosophia defensa et collaudata est, cum id, quod maxime placeat, facere possimus, omnis voluptas assumenda est, omnis dolor repellendus. Temporibus autem quibusdam et aut officiis debitis aut rerum necessitatibus saepe eveniet, ut et voluptates repudiandae sint et molestiae non recusandae. Itaque earum rerum defuturum, quas natura non depravata desiderat. Et quem ad me accedis, saluto: 'chaere,' inquam, 'Tite!' lictores, turma omnis chorusque: 'chaere, Tite!' hinc hostis mi Albucius, hinc inimicus. Sed iure Mucius. Ego autem mirari satis non queo unde hoc sit tam insolens domesticarum rerum fastidium. Non est omnino hic docendi locus; sed ita prorsus existimo, neque eum Torquatum, qui hoc primus cognomen invenerit, aut torquem illum hosti detraxisse, ut aliquam ex eo est consecutus? – Laudem et caritatem, quae sunt vitae sine metu degendae praesidia firmissima. – Filium morte multavit. – Si sine causa, nollem me ab eo delectari, quod ista Platonis, Aristoteli, Theophrasti orationis ornamenta neglexerit. Nam illud quidem physici, credere aliquid esse minimum, quod profecto numquam putavisset, si a Polyaeno, familiari suo, geometrica discere maluisset quam illum etiam ipsum dedocere. Sol Democrito magnus videtur, quippe homini erudito in geometriaque perfecto, huic pedalis fortasse; tantum enim esse omnino in nostris poetis aut inertissimae segnitiae est aut fastidii delicatissimi. Mihi quidem videtur, inermis ac nudus est. Tollit definitiones, nihil de dividendo ac partiendo docet, non quo ignorare vos arbitrer, sed ut ratione et via.

2. Opis zmian

Tabela 2.1: Historia zmian

Data	Co zostało zmienione
20.10.2026	Pierwsza wersja

3. Tło projektu

W celu pogłębienia wiedzy dotyczącej tematyki projektu oraz odpowiedniego przygotowania do jego realizacji przeprowadzono konsultacje z ekspertem oraz dokonano analizy istniejących rozwiązań o podobnym charakterze. Działania te miały na celu rozpoznanie dostępnych metod, identyfikację potencjalnych źródeł danych oraz wybór podejść badawczych, które mogą zostać wykorzystane w dalszych etapach prac.

3.1 Konsultacja z ludzkim ekspertem

W ramach przygotowań do realizacji projektu skonsultowano się z profesorem Jackiem Grekowem, aby uzyskać wskazówki dotyczące możliwych kierunków rozwoju rozwiązania. Podczas rozmowy poruszono zagadnienia związane z dostępnością gotowych modeli, pozyskiwaniem zbiorów danych, doborem odpowiednich metod uczenia maszynowego oraz zakresem zagadnień, które powinny zostać uwzględnione w pracy.

Jedną z zaproponowanych koncepcji było wykorzystanie metod ekstrakcji cech akustycznych z sygnału muzycznego, na przykład z zastosowaniem biblioteki **Essentia** [1]. W ten sposób możliwe jest uzyskanie zbioru parametrów opisujących poszczególne nagrania. Liczba wyodrębnionych cech może wynosić nawet kilkadziesiąt lub ponad sto, w zależności od przyjętej konfiguracji oraz charakterystyki analizowanego sygnału. Tak przygotowane dane mogłyby następnie posłużyć jako wejście dla algorytmu klasyfikacyjnego, takiego jak drzewo decyzyjne.

Alternatywnym podejściem jest zastosowanie konwolucyjnych sieci neuronowych (CNN, **Convolutional Neural Networks**), które mogą analizować reprezentację sygnału muzycznego w postaci spektrogramu. Rozwiązanie to umożliwia wykorzystanie metod głębokiego uczenia do rozpoznawania wzorców w strukturze czasowo-częstotliwościowej dźwięku. Ekspert zwrócił jednak uwagę na potencjalną wartość badawczą drzew decyzyjnych, między innymi ze względu na możliwość interpretacji procesu klasyfikacji oraz analizowania znaczenia poszczególnych cech wejściowych.

Podczas konsultacji omówiono również możliwość zastosowania zespołu klasyfikatorów. W przypadku opracowania trzech niezależnych modeli można wykorzystać metodę

głosowania większościowego (**majority voting**), w której ostateczna predykcja jest wyznaczana na podstawie wyniku wskazanego przez największą liczbę modeli. Podejście to mogłoby stanowić dodatkowy kierunek badań, pozwalający ocenić, czy połączenie kilku algorytmów poprawia skuteczność klasyfikacji.

Jako najbardziej uzasadniony kierunek dalszych prac ekspert zasugerował jednak skoncentrowanie się na porównaniu dwóch odmiennych podejść. W szczególności zaproponowano zestawienie klasyfikatora opartego na cechach akustycznych i drzewie decyzyjnym z modelem wykorzystującym konwolucyjną sieć neuronową analizującą spektrogramy. Takie porównanie pozwoliłoby ocenić skuteczność obu metod w realizacji założonego zadania, a także określić ich zalety i ograniczenia.

3.2 Konsultacja ze sztuczną inteligencją

W ramach przygotowań do realizacji projektu przeprowadzono konsultację ze sztuczną inteligencją. Wykorzystano w tym celu model językowy **ChatGPT** (OpenAI) dnia 20.10.2026. Celem konsultacji było uzyskanie dodatkowych wskazówek dotyczących wyboru zbiorów danych, metod uczenia maszynowego oraz sposobu przeprowadzenia eksperymentów. Konsultacja pozwoliła zidentyfikować potencjalne kierunki badań oraz zagadnienia, które warto uwzględnić podczas projektowania i oceny systemu rozpoznawania gatunków muzycznych.

W zakresie doboru danych zaproponowano wykorzystanie zbioru **FMA-medium (Free Music Archive)** [2] jako głównego źródła nagrań oraz zbioru **GTZAN** [3] do przeprowadzenia dodatkowych testów porównawczych. Zwrócono uwagę na ograniczenia zbioru GTZAN, w tym występowanie duplikatów nagrań, błędnych etykiet [4] oraz ryzyko uzyskania zawyżonych wyników w sytuacji, gdy utwory tego samego wykonawcy znajdują się jednocześnie w zbiorze treningowym i testowym. W związku z tym podkreślono znaczenie odpowiedniego podziału danych, uwzględniającego tożsamość wykonawców [5], co pozwala na bardziej wiarygodną ocenę zdolności modelu do klasyfikowania nieznanych wcześniej nagrań.

W odniesieniu do metod klasyfikacji zaproponowano rozważenie kilku podejść o różnym stopniu złożoności. Pierwszym z nich jest zastosowanie klasycznych algorytmów

uczenia maszynowego, takich jak drzewa decyzyjne, Random Forest lub SVM, wykorzystujących cechy akustyczne wyodrębnione z nagrań. Do cech tych mogą należeć między innymi współczynniki MFCC, charakterystyki widmowe, chroma oraz tempo utworu. Drugim podejściem jest wykorzystanie konwolucyjnych sieci neuronowych (CNN), które analizują spektrogramy muzyczne i samodzielnie uczą się rozpoznawać wzorce charakterystyczne dla poszczególnych gatunków. Dodatkowo wskazano możliwość wykorzystania gotowych, wcześniej wytrenowanych modeli, których reprezentacje dźwięku mogą stanowić dane wejściowe dla prostszego klasyfikatora.

Podczas konsultacji podkreślono, że istotnym elementem pracy powinno być nie tylko uzyskanie wysokiej skuteczności klasyfikacji, lecz także rzetelne porównanie zastosowanych metod. W tym celu zalecono uwzględnienie odpowiednich miar oceny, takich jak macro-F1, która umożliwia bardziej sprawiedliwe porównanie wyników dla poszczególnych klas w przypadku niezrównoważonego zbioru danych. Wskazano również na przydatność macierzy pomyłek, pozwalającej określić, które gatunki muzyczne są najczęściej ze sobą mylone. Ponadto zaproponowano przeprowadzenie eksperymentów z różnymi sposobami podziału danych oraz sprawdzenie, czy modele zachowują skuteczność podczas testowania na nagraniach pochodzących z innego zbioru niż ten wykorzystany w procesie uczenia.

Jako rekomendowany kierunek dalszych prac wskazano porównanie klasycznego podejścia opartego na ręcznie wyodrębnionych cechach akustycznych z metodą wykorzystującą głębokie uczenie na spektrogramach. Dodatkowym elementem badania mogłaby być ocena wpływu sposobu przygotowania danych na uzyskiwane wyniki. Takie podejście pozwoliłoby określić nie tylko, która z metod osiąga lepsze rezultaty, ale również jakie są jej ograniczenia oraz w jakim stopniu wyniki eksperymentalne odzwierciedlają rzeczywistą zdolność rozpoznawania gatunków muzycznych.

Wnioski z konsultacji ze sztuczną inteligencją stanowią uzupełnienie wskazówek uzyskanych podczas rozmowy z ekspertem. Pomagają doprecyzować plan badań, wskazać potencjalne problemy związane z jakością danych oraz zaplanować sposób porównania wybranych algorytmów. Ostateczny wybór zbiorów danych i metod powinien jednak uwzględniać zakres projektu, dostępne zasoby obliczeniowe oraz wyniki przeprowadzonych eksperymentów.

3.3 Przegląd podobnych rozwiązań

Automatyczne rozpoznawanie gatunków muzycznych (ang. *music genre recognition*, MGR) jest jednym z klasycznych zadań dziedziny pozyskiwania informacji z muzyki (*Music Information Retrieval*, MIR). Jedną z pierwszych szeroko cytowanych prac jest artykuł Tzanetakisa i Cooka [3], w którym klasyfikację oparto na ręcznie zaprojektowanych cechach opisujących barwę, rytm i wysokość dźwięku oraz na klasyfikatorach statystycznych. Praca ta wprowadziła również zbiór GTZAN, który przez kolejne lata stał się najczęściej używanym zbiorem testowym w tej dziedzinie [4].

Istniejące rozwiązania można podzielić na trzy grupy, odpowiadające podejściom omawianym podczas konsultacji.

Cechy akustyczne i klasyczne uczenie maszynowe. Z nagrania wyznaczany jest wektor cech (np. MFCC, charakterystyki widmowe, chroma, tempo), który trafia do klasyfikatora takiego jak drzewo decyzyjne, Random Forest lub SVM. Do ekstrakcji cech służą m.in. biblioteka Essentia [1] oraz librosa [6], a do klasyfikacji – scikit-learn [7]. Zaletą tej grupy jest niewielkie zapotrzebowanie na zasoby obliczeniowe i możliwość interpretacji modelu.

Konwolucyjne sieci neuronowe na spektrogramach. Sygnał jest przekształcany do reprezentacji czasowo-częstotliwościowej (np. mel-spektrogramu), a sieć sama uczy się cech istotnych dla klasyfikacji. Przykładem są konwolucyjno-rekurencyjne sieci do klasyfikacji muzyki [8] oraz sieci *musicnn* [9], zaprojektowane z myślą o dźwięku muzycznym.

Wstępnie wytrenowane reprezentacje (embeddingi). Model wytrenowany na dużym zbiorze (np. VGGish [10], model Google powiązany z AudioSet, lub transformery z rodziny MAEST [11]) zamienia nagranie na wektor, który następnie klasyfikuje prosty model, na przykład perceptron wielowarstwowy. Gotowe modele tego typu udostępnia projekt Essentia [12]; MAEST przewiduje taksonomię 400 stylów muzycznych opartą na metadanych serwisu Discogs.

Projekt realizowany w ramach niniejszej pracy koncentruje się na porównaniu dwóch pierwszych grup w jednolitym protokole eksperymentalnym, zgodnie z rekomendacją eksperta. Trzecia grupa pozostaje dodatkowym kierunkiem, który może posłużyć jako przyszły

punkt odniesienia w możliwym dalszym rozwoju projektu (np. do implementacji majority voting, tak jak sugerował to ekspert).

3.4 Stan wiedzy

Z literatury dotyczącej rozpoznawania gatunków muzycznych wynika kilka wniosków, które bezpośrednio wpływają na projekt eksperymentów.

Po pierwsze, jakość i sposób użycia zbioru danych mają równie duże znaczenie jak wybór algorytmu. Sturm [4] wykazał, że w GTZAN występują powtórzenia nagrań, błędne etykiety i zniekształcenia, a także liczne fragmenty tego samego wykonawcy w jednej klasie. Wnioskiem autora nie jest jednak porzucenie zbioru, lecz stosowanie go z uwzględnieniem jego wad. W projekcie GTZAN będzie zatem pełnił rolę pomocniczego zbioru kontrolnego, a nie jedynego źródła wniosków.

Po drugie, podział danych musi uwzględniać wykonawców. Flexer [5] pokazał, że umieszczenie utworów tego samego wykonawcy zarówno w zbiorze uczącym, jak i testowym zawyża wyniki klasyfikacji, ponieważ model uczy się rozpoznawać wykonawcę lub realizację nagrania, a nie gatunek. Dlatego w projekcie przyjęto podział rozłączny względem wykonawców (por. rozdział 4).

Po trzecie, zbiory o większej skali, takie jak FMA [2], powstały, ponieważ pozostałe zbiory z dostępnym dźwiękiem wysokiej jakości są o dwa rzędy wielkości mniejsze [2]. Wiąże się z tym jednak inna trudność: etykiety gatunkowe pochodzą z metadanych serwisu, a nie z niezależnej anotacji eksperckiej, więc granice między gatunkami bywają nieostre, a zbiór jest niezrównoważony.

Po czwarte, rozwój metod przesunął się od ręcznie projektowanych cech ku sieciom neuronowym i wstępnie wytrenowanym reprezentacjom [8], [9], [11]. Zalety klasycznego podejścia, przede wszystkim interpretowalność drzew decyzyjnych, uzasadniają jednak jego ponowne zestawienie z CNN. Do oceny stosuje się miary uwzględniające klasy niezrównoważone (macro-F1) oraz macierz pomyłek, wskazującą gatunki najczęściej ze sobą mylone.

3.5 Uwarunkowania licencyjne

Poniżej zestawiono licencje elementów, z których projekt korzysta lub może skorzystać: zbiorów danych, bibliotek oraz gotowych modeli. Informacje pochodzą ze stron projektów i dokumentacji wskazanych w bibliografii (stan na 27.10.2026). Przed publikacją wyników lub wydaniem kodu należy sprawdzić je ponownie, ponieważ licencje mogą ulec zmianie.

Tabela 3.1: Licencje zbiorów danych, bibliotek i modeli

Element	Licencja	Konsekwencje dla projektu
FMA – metadane	CC BY 4.0	Dowolne użycie z podaniem autorów zbioru [2].
FMA – nagrania	różne licencje Creative Commons, ustalane przez wykonawców	Użycie badawcze jest dopuszczalne. Część nagrań ma klauzule NC (bez użycia komercyjnego) lub ND (bez utworów zależnych) [13], [14].
GTZAN	brak jawnej licencji	Zbiór zawiera fragmenty komercyjnych nagrań [4]. Użycie wyłącznie badawcze, bez dalszego rozpowszechniania nagrań.
MTG-Jamendo	nagrania na licencjach Creative Commons (część z klauzulą NC); kod i metadane repozytorium Apache 2.0	Użycie badawcze jest dopuszczalne; użycie komercyjne wymaga wyboru nagrań na licencjach bez NC [15].
Essentia (biblioteka)	AGPL-3.0; licencja komercyjna na zamówienie	Dla pracy dyplomowej bez udostępniania usługi sieciowej obowiązki są ograniczone. Wdrożenie komercyjne wymaga licencji lub zamiany biblioteki [16].
Modele Essentia, MAEST	CC BY-NC-SA 4.0 (wg pliku licencji modeli); licencja zastrzeżona na zamówienie	Wyłącznie użycie niekomercyjne. Strona opisująca licencjonowanie wymienia wariant BY-NC-ND, dlatego warunki konkretnego modelu należy sprawdzić przy jego pobraniu [16], [17].
VGGish, YAMNet	Apache 2.0	Dopuszczalne także użycie komercyjne [17].
musicnn	ISC	Licencja permisywna [17].
librosa	ISC	Licencja permisywna [6].
scikit-learn	BSD 3-Clause	Licencja permisywna [7].
PyTorch / TensorFlow	BSD / Apache 2.0	Licencje permisywne, dozwolone użycie komercyjne.

Z zestawienia (Tabela 3.1) wynikają dwie obserwacje. Po pierwsze, licencje Creative Commons z klauzulą NC lub ND dotyczą większości nagrań w zbiorze FMA, a udział nagrań na licencji CC BY 4.0 jest niewielki [14]. Po drugie, wstępnie wytrenowane modele Essentia i MAEST są udostępniane na licencji niekomercyjnej, a prawo do użycia komercyjnego trzeba uzyskać odrębnie.

Warto zaznaczyć, że sam proces uczenia modelu nie polega na redystrybucji nagrań, lecz na ich analizie. Dyrektywa (UE) 2019/790 przewiduje wyjątki dla eksploracji tekstu i danych (art. 3 dla organizacji badawczych, art. 4 z możliwością zastrzeżenia przez uprawnionych) [18]. Nie rozstrzyga to jednak wszystkich wątpliwości dotyczących nagrań z klauzulą ND, dlatego przyjęto ostrożne podejście opisane w kolejnym podrozdziale.

3.6 Uwarunkowania komercyjne

Projekt jest pracą dyplomową o charakterze badawczym i edukacyjnym, a jego wyniki nie będą oferowane jako produkt ani usługa. W tych warunkach:

- korzystanie z nagrań FMA, MTG-Jamendo i GTZAN w celach badawczych jest dopuszczalne,
- korzystanie z biblioteki Essentia na licencji AGPL-3.0 oraz z jej modeli na licencji niekomercyjnej jest dopuszczalne,
- nagrania, spektrogramy ani inne dane pochodne nie będą rozpowszechniane; w repozytorium publikowane będą identyfikatory utworów i skrypty pobierania danych,
- w pracy podane zostaną źródła zbiorów i bibliotek zgodnie z wymaganiami ich licencji (w szczególności atrybucja dla CC BY).

Modele wytrenowane w projekcie na danych z klauzulą NC będą traktowane jako niekomercyjne, nawet jeśli prawne skutki takiego uczenia nie są jednoznaczne. Ewentualna komercjalizacja rozwiązania wymagałaby: ograniczenia danych do nagrań na licencjach bez NC i ND albo pozyskania własnych praw do nagrań, zastąpienia biblioteki Essentia i jej modeli rozwiązaniami permisywnymi (np. librosa, VGGish) albo wykupienia licencji komercyjnej oraz ponownego wytrenowania modeli. Powyższa analiza ma charakter informacyjny

i nie stanowi porady prawnej; w razie wątpliwości należy skonsultować się z opiekunem pracy lub działem prawnym uczelni.

3.7 Dostępne bazy danych

W projekcie rozważano trzy zbiory danych. Ich podstawowe parametry zestawiono w Tabela 3.2.

Tabela 3.2: Porównanie dostępnych zbiorów danych

Zbiór	**Rozmiar**	**Etykiety**	**Uwagi**
GTZAN	1000 fragmentów po 30 s	10 gatunków po 100 fragmentów	Zbalansowany i mały; znane wady: powtórzenia, błędne etykiety, silna obecność pojedynczych wykonawców w klasach [4].
FMA (small)	8000 fragmentów po 30 s	8 gatunków po 1000 fragmentów	Najmniejszy wariant FMA, zbalansowany [2].
FMA (medium)	25 000 fragmentów po 30 s	16 gatunków nadrzędnych, niezrównoważone	Główny kandydat projektu. Dostępne metadane z wykonawcą, co umożliwia podział rozłączny względem wykonawców [2].
FMA (large, full)	106 574 utwory	161 gatunków w hierarchii	Wariant *large* zawiera fragmenty 30 s, wariant *full* pełne nagrania. Bardzo duże, przekraczające założone zasoby obliczeniowe projektu [2].
MTG-Jamendo	ponad 55 000 pełnych nagrań	195 tagów, w tym 87 gatunkowych; wielokrotne etykiety	Zadanie wieloetykietowe, co odbiega od założenia jednego gatunku na utwór [15].

GTZAN jest najczęściej używanym zbiorem w literaturze, dzięki czemu pozwala porównać wyniki z pracami innych autorów, ale ze względu na wady opisane w stanie wiedzy nie nadaje się na jedyny zbiór oceny. **FMA** jest największym otwartym zbiorem z nagraniami

o dobrej jakości, metadanymi wykonawców i hierarchią gatunków, a zostało przygotowane do oceny algorytmów MIR [2]. Wariant *medium* stanowi kompromis między liczbą danych a zasobami obliczeniowymi. **MTG-Jamendo** jest przeznaczony do automatycznego tagowania, czyli zadania wieloetykietowego, więc jego użycie wymagałoby zmiany sformułowania problemu. W pozostałych zbiorach spotykanych w literaturze (np. MagnaTagATune, Million Song Dataset, AudioSet) dostępność nagrań lub ich jakość stanowią ograniczenie [2], dlatego nie zostały uwzględnione.

Na podstawie powyższej analizy jako zbiór główny wybrano FMA (medium), a jako zbiór do dodatkowych testów porównawczych i oceny na danych z innego źródła – GTZAN. Konkretny podzbiór gatunków i kryteria sukcesu opisano w rozdziale 4.

4. Analiza wymagań

4.1 Cel projektu

Celem projektu jest opracowanie i ocena modelu uczenia maszynowego umożliwiającego automatyczne rozpoznawanie gatunków muzycznych na podstawie sygnału audio. Zadanie polega na przyporządkowaniu utworu do jednej z **5 wcześniej zdefiniowanych kategorii (gatunków)** wybranych ze zbioru FMA (por. podrozdział *Zakres danych i kryteria sukcesu*). Sukces projektu mierzony jest ilościowo: celem jest osiągnięcie przez sieć CNN wartości macro-F1 co najmniej 0,60 oraz F1 co najmniej 0,50 dla co najmniej 3 z 5 gatunków, a przez drzewo decyzyjne macro-F1 co najmniej 0,45 (szczegóły w Tabela 4.1).

4.2 Charakterystyka problemu

Rozpoznawanie gatunków muzycznych jest problemem klasyfikacji nadzorowanej. Model uczy się na podstawie utworów z przypisanymi etykietami, a następnie klasyfikuje nieznane próbki. Trudność wynika z podobieństw między gatunkami oraz różnorodności tempa, instrumentacji, aranżacji i jakości nagrań.

4.3 Metody badawcze

W projekcie zostaną wykorzystane sieci neuronowe typu CNN oraz drzewa decyzyjne. Modele zostaną wytrenowane i przetestowane na przygotowanym zbiorze danych, a następnie porównane pod względem skuteczności rozpoznawania gatunków muzycznych. Dane zostaną podzielone na zbiór treningowy, walidacyjny i testowy w proporcji 70/15/15, przy czym podział będzie rozłączny względem wykonawców (żaden wykonawca nie wystąpi w więcej niż jednym zbiorze) [5].

4.4 Oczekiwane rezultaty

Oczekiwanym rezultatem jest opracowanie modelu klasyfikującego utwory muzyczne oraz porównanie skuteczności wybranych metod. Analiza pozwoli określić, które cechy

audio i algorytmy sprawdzają się najlepiej oraz jakie ograniczenia występują w procesie klasyfikacji.

4.5 Zakres danych i kryteria sukcesu

Zbiorem głównym jest FMA-medium, w którym dostępnych jest 16 gatunków nadrzędnych o bardzo nierównej liczebności [2]. Do eksperymentów wybrano **5 gatunków**: Classical, Hip-Hop, Jazz, Pop i Rock. Liczba ta pozwala utrzymać zbalansowane klasy przy rozsądnej liczbie nagrań. Przy 5 klasach skuteczność klasyfikatora losowego wynosi 20%, co jest punktem odniesienia dla wyników. Liczebność klas zostanie wyrównana przez losowe ograniczenie liczby utworów do najmniejszej z wybranych klas (nie mniej niż 300 utworów na klasę).

Do oceny na danych z innego źródła wykorzystany zostanie zbiór GTZAN [3] ograniczony do **5 gatunków wspólnych** z listą FMA: Classical, Hip-Hop, Jazz, Pop i Rock.

Kryteria sukcesu. Przyjęto następujące cele ilościowe. Mają one charakter roboczy i zostaną zweryfikowane po pierwszym eksperymencie wstępnym.

Tabela 4.1: Cele ilościowe projektu

Kryterium	**CNN**	**Drzewo decyzyjne**
macro-F1 na zbiorze testowym FMA (5 klas)	$\geq 0{,}60$	$\geq 0{,}45$
liczba klas z F1 $\geq 0{,}50$ (udział klas)	≥ 3 z 5 (60%)	≥ 2 z 5 (40%)
najgorsza klasa: F1	$\geq 0{,}30$	$\geq 0{,}20$
macro-F1 na GTZAN (5 klas wspólnych)	$\geq 0{,}40$	$\geq 0{,}30$
powtarzalność: odchylenie standardowe macro-F1 z 3 ziaren	$\leq 0{,}03$	$\leq 0{,}03$

Wartości te należy odnosić do skuteczności klasyfikatora losowego (20% przy 5 klasach, zarówno na FMA, jak i na GTZAN). Za wynik minimalny, poniżej którego eksperyment uznaje się za nieudany, przyjmuje się macro-F1 niższe niż dwukrotność tej wartości. O przewadze jednej metody nad drugą wnioskuje się wyłącznie wtedy, gdy różnica macro-F1 przekracza zmienność między uruchomieniami (3 ziarna losowości) i mieści się poza 95% przedziałem ufności wyznaczonym metodą bootstrap. Dodatkowo raportowana będzie dokładność (accuracy) oraz macierz pomyłek.

4.6 Wymagania funkcjonalne

- Wczytanie nagrania audio i przygotowanie danych wejściowych (cechy akustyczne dla drzewa decyzyjnego, spektrogramy dla sieci CNN).
- Klasyfikacja utworu do jednego ze zdefiniowanych gatunków muzycznych.
- Ocena obu modeli na zbiorze testowym i porównanie ich wyników.

4.7 Wymagania niefunkcjonalne

- Powtarzalność eksperymentów (stały podział danych rozłączny względem wykonawców, zapisane ziarno losowości, 3 uruchomienia z różnymi ziarnami).
- Ocena skuteczności za pomocą standardowych miar: macro-F1 (miara główna), dokładność, F1 dla każdej klasy i macierz pomyłek.

4.8 Założenia i kwestie do ustalenia

Zakłada się, że każdy utwór jest przypisany do jednego gatunku, a jako etykiety przyjmowany jest gatunek nadrzędny z metadanych FMA. Zbiór główny (FMA-medium) i zbiór pomocniczy (GTZAN) zostały wybrane na podstawie analizy opisanej w rozdziale 3. Do ostatecznego zatwierdzenia pozostają: lista 5 gatunków (po sprawdzeniu liczebności klas) oraz progi z Tabela 4.1, które mogą zostać skorygowane po eksperymencie wstępnym.

5. Zakres projektu i harmonogram

Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do eiusmod tempor incididunt ut labore et dolore magnam aliquam quaerat voluptatem. Ut enim aeque doleamus animo, cum corpore dolemus, fieri tamen permagna accessio potest, si aliquod aeternum et infinitum impendere malum nobis opinemur. Quod idem licet transferre in voluptatem, ut postea variari voluptas distinguique possit, augeri amplificarique non possit. At etiam Athenis, ut e patre audiebam facete et urbane Stoicos irridente, statua est in quo a nobis philosophia defensa et collaudata est, cum id, quod maxime placeat, facere possimus, omnis voluptas assumenda est, omnis dolor repellendus. Temporibus autem quibusdam et aut officiis debitis aut rerum necessitatibus saepe eveniet, ut et voluptates repudiandae sint et molestiae non recusandae. Itaque earum rerum defuturum, quas natura non depravata desiderat. Et quem ad me accedis, saluto: 'chaere,' inquam, 'Tite!' lictores, turma omnis chorusque: 'chaere, Tite!' hinc hostis mi Albucius, hinc inimicus. Sed iure Mucius. Ego autem mirari satis non queo unde hoc sit tam insolens domesticarum rerum fastidium. Non est omnino hic docendi locus; sed ita prorsus existimo, neque eum Torquatum, qui hoc primus cognomen invenerit, aut torquem illum hosti detraxisse, ut aliquam ex eo est consecutus? – Laudem et caritatem, quae sunt vitae sine metu degendae praesidia firmissima. – Filium morte multavit. – Si sine causa, nollem me ab eo delectari, quod ista Platonis, Aristoteli, Theophrasti orationis ornamenta neglexerit. Nam illud quidem physici, credere aliquid esse minimum, quod profecto numquam putavisset, si a Polyaeno, familiari suo, geometrica discere maluisset quam illum etiam ipsum dedocere. Sol Democrito magnus videtur, quippe homini erudito in geometriaque perfecto, huic pedalis fortasse; tantum enim esse omnino in nostris poetis aut inertissimae segnitiae est aut fastidii delicatissimi. Mihi quidem videtur, inermis ac nudus est. Tollit definitiones, nihil de dividendo ac partiendo docet, non quo ignorare vos arbitrer, sed ut ratione et via.

6. Szczegółowa specyfikacja projektu i opis wymagań

Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do eiusmod tempor incididunt ut labore et dolore magnam aliquam quaerat voluptatem. Ut enim aeque doleamus animo, cum corpore dolemus, fieri tamen permagna accessio potest, si aliquod aeternum et infinitum impendere malum nobis opinemur. Quod idem licet transferre in voluptatem, ut postea variari voluptas distinguique possit, augeri amplificarique non possit. At etiam Athenis, ut e patre audiebam facete et urbane Stoicos irridente, statua est in quo a nobis philosophia defensa et collaudata est, cum id, quod maxime placeat, facere possimus, omnis voluptas assumenda est, omnis dolor repellendus. Temporibus autem quibusdam et aut officiis debitis aut rerum necessitatibus saepe eveniet, ut et voluptates repudiandae sint et molestiae non recusandae. Itaque earum rerum defuturum, quas natura non depravata desiderat. Et quem ad me accedis, saluto: 'chaere,' inquam, 'Tite!' lictores, turma omnis chorusque: 'chaere, Tite!' hinc hostis mi Albucius, hinc inimicus. Sed iure Mucius. Ego autem mirari satis non queo unde hoc sit tam insolens domesticarum rerum fastidium. Non est omnino hic docendi locus; sed ita prorsus existimo, neque eum Torquatum, qui hoc primus cognomen invenerit, aut torquem illum hosti detraxisse, ut aliquam ex eo est consecutus? – Laudem et caritatem, quae sunt vitae sine metu degendae praesidia firmissima. – Filium morte multavit. – Si sine causa, nollem me ab eo delectari, quod ista Platonis, Aristoteli, Theophrasti orationis ornamenta neglexerit. Nam illud quidem physici, credere aliquid esse minimum, quod profecto numquam putavisset, si a Polyaeno, familiari suo, geometrica discere maluisset quam illum etiam ipsum dedocere. Sol Democrito magnus videtur, quippe homini erudito in geometriaque perfecto, huic pedalis fortasse; tantum enim esse omnino in nostris poetis aut inertissimae segnitiae est aut fastidii delicatissimi. Mihi quidem videtur, inermis ac nudus est. Tollit definitiones, nihil de dividendo ac partiendo docet, non quo ignorare vos arbitrer, sed ut ratione et via.

7. Opis wyników prac

Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do eiusmod tempor incididunt ut labore et dolore magnam aliquam quaerat voluptatem. Ut enim aeque doleamus animo, cum corpore dolemus, fieri tamen permagna accessio potest, si aliquod aeternum et infinitum impendere malum nobis opinemur. Quod idem licet transferre in voluptatem, ut postea variari voluptas distinguique possit, augeri amplificarique non possit. At etiam Athenis, ut e patre audiebam facete et urbane Stoicos irridente, statua est in quo a nobis philosophia defensa et collaudata est, cum id, quod maxime placeat, facere possimus, omnis voluptas assumenda est, omnis dolor repellendus. Temporibus autem quibusdam et aut officiis debitis aut rerum necessitatibus saepe eveniet, ut et voluptates repudiandae sint et molestiae non recusandae. Itaque earum rerum defuturum, quas natura non depravata desiderat. Et quem ad me accedis, saluto: 'chaere,' inquam, 'Tite!' lictores, turma omnis chorusque: 'chaere, Tite!' hinc hostis mi Albucius, hinc inimicus. Sed iure Mucius. Ego autem mirari satis non queo unde hoc sit tam insolens domesticarum rerum fastidium. Non est omnino hic docendi locus; sed ita prorsus existimo, neque eum Torquatum, qui hoc primus cognomen invenerit, aut torquem illum hosti detraxisse, ut aliquam ex eo est consecutus? – Laudem et caritatem, quae sunt vitae sine metu degendae praesidia firmissima. – Filium morte multavit. – Si sine causa, nollem me ab eo delectari, quod ista Platonis, Aristoteli, Theophrasti orationis ornamenta neglexerit. Nam illud quidem physici, credere aliquid esse minimum, quod profecto numquam putavisset, si a Polyaeno, familiari suo, geometrica discere maluisset quam illum etiam ipsum dedocere. Sol Democrito magnus videtur, quippe homini erudito in geometriaque perfecto, huic pedalis fortasse; tantum enim esse omnino in nostris poetis aut inertissimae segnitiae est aut fastidii delicatissimi. Mihi quidem videtur, inermis ac nudus est. Tollit definitiones, nihil de dividendo ac partiendo docet, non quo ignorare vos arbitrer, sed ut ratione et via.

8. Oświadczenie wykorzystania narzędzi GenAI

W trakcie realizacji projektu wykorzystano następujące narzędzia generatywnej sztucznej inteligencji:

- **ChatGPT** (OpenAI) – do konsultacji dotyczących wyboru zbiorów danych, metod uczenia maszynowego i miar oceny; zakres konsultacji i ich wnioski opisano w rozdziale 3. Wykorzystywano go również do poprawek językowych i ortograficznych.
- **Claude** (Anthropic) – do przygotowania szablonu dokumentu w systemie Typst oraz pomocy przy redakcji części tekstu do formatu typst.

Wyniki uzyskane z narzędzi GenAI zostały zweryfikowane przez autorów pracy na podstawie źródeł wskazanych w bibliografii.

Bibliografia

[1] D. Bogdanov *et al.*, „Essentia: an audio analysis library for music information retrieval", w *International Society for Music Information Retrieval Conference (ISMIR)*, 2013, s. 493–498.

[2] M. Defferrard, K. Benzi, P. Vandergheynst, i X. Bresson, „FMA: A dataset for music analysis", w *International Society for Music Information Retrieval Conference (ISMIR)*, 2017.

[3] G. Tzanetakis i P. Cook, „Musical genre classification of audio signals", *IEEE Transactions on Speech and Audio Processing*, t. 10, nr 5, s. 293–302, 2002, doi: 10.1109/TSA.2002.800560.

[4] B. L. Sturm, „The GTZAN dataset: Its contents, its faults, their effects on evaluation, and its future use", *Journal of New Music Research*, t. 43, nr 2, s. 147–172, 2014, doi: 10.1080/09298215.2014.894533.

[5] A. Flexer, „A closer look on artist filters for musical genre classification", w *International Society for Music Information Retrieval Conference (ISMIR)*, 2007.

[6] B. McFee *et al.*, „librosa: Audio and music signal analysis in Python", w *Proceedings of the 14th Python in Science Conference*, 2015, s. 18–25.

[7] F. Pedregosa i others, „Scikit-learn: Machine learning in Python", *Journal of Machine Learning Research*, t. 12, s. 2825–2830, 2011.

[8] K. Choi, G. Fazekas, M. Sandler, i K. Cho, „Convolutional recurrent neural networks for music classification”, w *IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 2017.

[9] J. Pons i X. Serra, „musicnn: Pre-trained convolutional neural networks for music audio tagging”, w *Late-breaking/demo session, International Society for Music Information Retrieval Conference (ISMIR)*, 2019.

[10] S. Hershey i others, „CNN architectures for large-scale audio classification”, w *IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 2017.

[11] P. Alonso-Jiménez, X. Serra, i D. Bogdanov, „Efficient supervised training of audio transformers for music representation learning”, w *International Society for Music Information Retrieval Conference (ISMIR)*, 2023.

[12] „Essentia models. Music Technology Group, UPF. Witryna internetowa”.

[13] „FMA: A dataset for music analysis. Repozytorium kodu i danych. Witryna internetowa”.

[14] „FMA: zestawienie licencji nagrań wg czasu trwania. Witryna internetowa (Hugging Face)”.

[15] D. Bogdanov, M. Won, P. Tovstogan, A. Porter, i X. Serra, „The MTG-Jamendo dataset for automatic music tagging”, w *Machine Learning for Music Discovery Workshop, International Conference on Machine Learning (ICML)*, 2019.

[16] „Licensing Essentia. Essentia, Music Technology Group, UPF. Witryna internetowa”.

[17] „Essentia models: licencje i pochodzenie modeli. Witryna internetowa”.

[18] „Dyrektywa Parlamentu Europejskiego i Rady (UE) 2019/790 z dnia 17 kwietnia 2019 r. w sprawie prawa autorskiego i praw pokrewnych na jednolitym rynku cyfrowym”. 2019.

Spis tabel

2.1 Historia zmian. 2
3.1 Licencje zbiorów danych, bibliotek i modeli. 9
3.2 Porównanie dostępnych zbiorów danych. 11
4.1 Cele ilościowe projektu. 14

Spis rysunków

Spis listingów

Spis algorytmów